LAB 05 — DỰ ĐOÁN TRƯỚC THỰC NGHIỆM (PREDICTIONS)

Tài Liệu Phân Tích & Thực Nghiệm Khoa Học

October 21, 2026

Tài liệu này ghi nhận các giả thuyết và dự đoán khoa học được lập ra **hoàn toàn trước khi tiến hành huấn luyện các mô hình** trên tập dữ liệu IMDb Movie Reviews theo yêu cầu tại Mục 10 của đề bài LAB 05.

—

1. Prediction 1: Khả Năng Xử Lý Trật Tự Từ (Word Order)

1.1. So sánh

Giữa mô hình **TF-IDF + Logistic Regression** và **RNN + Word Embedding**.

1.2. Dự đoán (Prediction)

Mô hình **RNN + Word Embedding** có khả năng mô hình hóa và xử lý trật tự từ trực tiếp, linh hoạt và bản chất hơn rất nhiều so với TF-IDF + Logistic Regression.

1.3. Lý giải cơ chế (Reason)

- **Mô hình TF-IDF + Logistic Regression**: Biểu diễn văn bản dựa trên giả thiết túi từ (Bag-of-Words). Ma trận TF-IDF đếm tần suất xuất hiện của từ độc lập trong văn bản, hoàn toàn làm mất thông tin về vị trí tương đối và trật tự cú pháp. Dù có thể mở rộng lên n-gram (như bigram, trigram), cách này vẫn chỉ chụp được các cụm từ cục bộ cố định trong cửa sổ n rất nhỏ và dẫn tới bùng nổ chiều đặc trưng (curse of dimensionality), không thể mô hình hóa được sự chuyển dịch trạng thái ngữ nghĩa theo thời gian.
- **Mô hình RNN + Word Embedding**: Cơ chế recurrent computation $h_t = \tanh(W_{xh}x_t + W_{hh}h_{t-1} + b_h)$ xử lý từng token tuần tự theo thời gian. Mỗi từ mới đọc vào tương tác phi tuyến trực tiếp với trạng thái nén của toàn bộ tiền ngữ cảnh h_{t-1}. Do đó, hoán đổi vị trí của hai từ (ví dụ: ”not bad” so với ”bad not”) sẽ tạo ra các quỹ đạo trạng thái ẩn h_t hoàn toàn khác nhau.

1.4. Độ tự tin (Confidence)

Rất cao (High — 95%).

1.5. Tiêu chí kiểm chứng (Verification Criteria)

So sánh khả năng phân loại trên các câu đối xứng có cùng tập từ nhưng đảo vị trí từ phủ định hoặc vai trò chủ ngữ - vị ngữ.

—

2. Prediction 2: Khả Năng Xử Lý Phụ Thuộc Xa (Long-Range Dependency)

2.1. So sánh

Giữa mô hình **Simple RNN** và mô hình **LSTM (Long Short-Term Memory)**.

2.2. Dự đoán (Prediction)

Mô hình **LSTM** sẽ xử lý các mối phụ thuộc tầm xa (long-range dependencies) vượt trội hơn hẳn so với Simple RNN, đặc biệt trên các đoạn văn bản dài có thông tin quyết định nằm rải rác hoặc cách xa nhau.

2.3. Lý giải cơ chế (Reason)

- **Simple RNN**: Gradient khi lan truyền ngược qua thời gian (BPTT) bị nhân liên tiếp qua $T-t$ ma trận trọng số W_{hh}^T và đạo hàm của hàm tanh. Do đạo hàm $|\tanh'(z)| \leq 1$ và chuẩn ma trận thường nhỏ hơn 1, tích dồn này suy giảm theo hàm mũ, dẫn tới triệt tiêu gradient (vanishing gradient). Tín hiệu từ các token ở đầu câu dài gần như không còn tác dụng cập nhật trọng số ở các bước sau.
- **LSTM**: Đưa vào trạng thái ô nhớ chuyên biệt c_t (Cell State) với biểu thức cập nhật tuyến tính cộng dồn:

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t$$

Khi forget gate $f_t \approx 1$, đạo hàm $\frac{\partial c_t}{\partial c_{t-1}} = f_t \approx 1$. Gradient có thể chảy thẳng qua hàng chục hoặc hàng trăm timestep dọc theo "đường cao tốc gradient" (gradient highway) mà không bị suy giảm hàm mũ. Nhờ đó, LSTM duy trì được bộ nhớ dài hạn hữu hiệu.

2.4. Độ tự tin (Confidence)

Rất cao (High — 95%).

2.5. Tiêu chí kiểm chứng (Verification Criteria)

Kiểm tra độ chính xác phân loại và độ nhạy của mô hình khi thử nghiệm câu có từ khóa cảm xúc đặt ở đầu câu, giữa câu và cuối câu (Experiment 6).

—

3. Prediction 3: Ảnh Hưởng Khi Tăng Chiều Dài Chuỗi ($50 \rightarrow 200$)

3.1. Bài toán

Khi tăng tham số độ dài cắt chuỗi $\texttt{max}_l ength ca Simple RNN t \texttt{50} ln \texttt{200} tokens$.

3.2. Dự đoán (Prediction)

1. `Thời gian huấn luyện mỗi epoch: Sẽ tăng tuyến tính xấp xỉ từ 3 đến 4 lần.`
1. `Khả năng học của Simple RNN: Hiệu năng (F1/Accuracy) có thể tăng nhẹ ở mức độ vừa phải nhờ tiếp nhận thêm ngữ cảnh, nhưng sau đó sẽ bão hòa rất nhanh hoặc thậm chí suy giảm/không ổn định do hiện tượng triệt tiêu gradient và bùng nổ gradient trên chuỗi dài 200 bước.`

3.3. Lý giải cơ chế (Reason)

- `Độ phức tạp tính toán của forward và backward trong RNN tỉ lệ thuận tuyến tính với số timestep:` $\mathcal{O}(T \times d \times h)$`. Khi` T `tăng từ` 50 `lên` 200`, số phép nhân ma trận tăng gấp 4 lần.`
- `Chuỗi dài 200 đòi hỏi BPTT phải unroll qua 200 bước. Với Simple RNN, việc lan truyền tín hiệu gradient qua 200 ma trận liên tiếp hầu như triệt tiêu hoàn toàn thông tin ở các bước đầu, đồng thời làm hàm mục tiêu trở nên gồ ghề hơn, dễ dẫn đến mất ổn định khi tối ưu hóa.`

3.4. Độ tự tin (Confidence)

`Cao (High - 90%).`

3.5. Tiêu chí kiểm chứng (Verification Criteria)

`Bảng số liệu Experiment 2 và Experiment 5 so sánh thời gian chạy (Training time) và chỉ số F1 giữa các mốc` $50, 100, 200$`.`

---

4. Prediction 4: Tác Động Khi Cắt Cụt Review Về 30 Tokens

4.1. Bài toán

Nếu cắt cụt (truncate) toàn bộ review của tập IMDb về độ dài chỉ còn 30 tokens.

4.2. Dự đoán (Prediction)

Độ chính xác và độ bao quát phân loại cảm xúc sẽ **bị suy giảm nghiêm trọng** (dự kiến giảm từ 5% đến 15% F1 so với độ dài đầy đủ).

4.3. Lý giải cơ chế (Reason)

- Các bài đánh giá phim trên IMDb thường có phong cách viết tự sự mở đầu: tác giả thường giới thiệu bối cảnh phim, dàn diễn viên, đạo diễn hoặc kể lại cốt truyện trong 2-3 câu đầu tiên (chiếm hơn 30-50 từ).
- Nhận xét khen/chê chốt hạ thường xuất hiện ở phần giữa hoặc câu kết luận ("Overall, this is a masterpiece" hoặc "However, the ending ruined everything").
- Khi cắt ở ngưỡng 30 tokens, toàn bộ ngữ cảnh quan trọng mang tính đảo chiều (contrastive clauses) và kết luận cảm xúc ở phần sau sẽ bị vứt bỏ hoàn toàn. Mô hình buộc phải đoán dựa trên các đoạn mở đầu mang tính trung tính hoặc dễ gây nhầm lẫn.

4.4. Độ tự tin (Confidence)

Rất cao (High - 95%).

4.5. Tiêu chí kiểm chứng (Verification Criteria)

So sánh tỉ lệ phần trăm từ vựng giữ lại (% tokens retained) và quan sát các mẫu phân loại sai do mất thông tin kết luận trong $error_analysis.md$.

---

5. Prediction 5: LSTM Có Chắc Chắn Thắng Tuyệt Đối Trên Mọi Dataset?

5.1. Câu hỏi

Liệu LSTM có đảm bảo luôn cho accuracy cao hơn Simple RNN và Logistic Regression trên mọi tập dữ liệu hay không?

5.2. Dự đoán (Prediction)

Không. LSTM không thể đảm bảo luôn vượt trội trên mọi dataset. Sẽ có những trường hợp Simple RNN hoặc thậm chí Logistic Regression đạt hiệu năng tương đương hoặc tốt hơn LSTM.

5.3. Lý giải cơ chế (Reason)

1. **Hiện tượng Overfitting do số lượng tham số lớn**: LSTM sở hữu 4 bộ trọng số riêng biệt (W_f, W_i, W_c, W_o), có số tham số gấp 4 lần Simple RNN. Nếu tập dữ liệu huấn luyện nhỏ, nghèo nàn hoặc văn bản ngắn, LSTM rất dễ overfit vào tập train và khái quát hóa kém trên tập test.
1. **Đặc trưng dạng túi từ đủ mạnh**: Với các bài toán phân loại đơn giản dựa trên từ khóa phân cực rõ rệt (sentiment polarity lexicon) mà thứ tự từ không làm đổi nghĩa, Linear model (Logistic Regression) với regularization mạnh có thể đạt độ chính xác tương đương mô hình sâu mà không chịu rủi ro gradient vanishing/exploding.
1. **Chi phí hội tụ**: LSTM đòi hỏi nhiều epoch hơn và không gian tối ưu phức tạp hơn nhiều so với Simple RNN.

5.4. Độ tự tin (Confidence)

Rất cao (High - 95%).

5.5. Tiêu chí kiểm chứng (Verification Criteria)

So sánh baseline Logistic Regression với RNN và LSTM trong bảng results.csv, đồng thời đối chiếu với các nghiên cứu thực nghiệm trong tài liệu NLP.