LAB 06 — ATTENTION MECHANISM: ERROR ANALYSIS

Tài Liệu Phân Tích & Thực Nghiệm Khoa Học

October 25, 2026

Môn học: Xử lý ngôn ngữ tự nhiên và ứng dụng
Học kỳ: Học kỳ I - 2026
Chủ đề: From Recurrent State to Context-Aware Representation
Dữ liệu thực nghiệm: 1,500 mẫu kiểm thử chuẩn tập IMDb Movie Reviews
—

1. Phương Pháp Luận Và Tiêu Chí Đánh Giá Lỗi

Phân tích định tính lỗi thực nghiệm đóng vai trò cầu nối quan trọng giữa các độ đo định lượng tổng quát (như Accuracy 76.33%, F1 76.69%) và bản chất cơ chế bên trong của mô hình. Trong LAB 06, việc đưa vào tầng **Self-Attention** cho phép chúng ta không chỉ quan sát nhãn dự đoán cuối cùng mà còn trực tiếp khảo sát **ma trận trọng số phân bổ chú ý** α_{ij} để kiểm nghiệm giả thuyết:

> *Mô hình đang định tuyến thông tin ngữ cảnh qua các token nào, và liệu sự định tuyến này có phản ánh đúng ngữ nghĩa hay bị dẫn dụ bởi các đặc trưng giả (spurious correlations)?*

Theo đúng quy chuẩn học thuật, toàn bộ 6 mẫu dưới đây (3 dự đoán đúng, 3 dự đoán sai) được trích xuất trực tiếp từ kết quả chạy thực nghiệm thật trên tập kiểm thử (Test set) của mô hình `SelfAttentionClassifier` (652,353 tham số, độ dài $T = 100$, 5 epochs).
—

2. Bảng Tổng Hợp 6 Mẫu Kiểm Thử Thực Tế

STT	Trích đoạn văn bản (Text snippet)	True Label	Predicted	Prob (Pos)	Phân loại lỗi (Taxonomy)	Kết quả
1	*”the tortuous emotional impact is degrading, whether adult or adolescent the personal values shown in this movie belong in...”*	Negative (0)	Negative (0)	**0.0072**	N/A (Polarized negative)	**ĐÚNG**
2	*”let me set the scene. it is the school holidays and there is absolutely nothing at the movies. i am with my friend decided to watch this great film...”*	Positive (1)	Positive (1)	**0.9166**	N/A (Salient positive)	**ĐÚNG**
3	*”i’ve seen my share of woody allen’s movies, and while they’re not always great, you can usually be sure you’re going to get disappointed by this one...”*	Negative (0)	Negative (0)	**0.3890**	N/A (Nuanced contrast)	**ĐÚNG**
4	*”paul muni and bette davis overact monstrously while lacklustre studio hack archie mayo seems*	**Negative (0)**	**Positive (1)**	**0.9856**	**Rare Words / Named Entities**	**SAI**

—

3. Phân Tích Chi Tiết Các Trường Hợp Dự Đoán Đúng

Trường hợp 1: Phân cực tiêu cực cực mạnh (Sample 3)

- **Văn bản**: *"the tortuous emotional impact is degrading, whether adult or adolescent the personal values shown in this movie belong in..."*

- **Nhãn gốc (Ground Truth): Negative (0)**	**Dự đoán: Negative (0)**	**Xác suất tích cực:** 0.0072 **(**0.72%**).**

- **Phân tích Attention**:
- Mô hình tập trung trọng số lớn vào các từ khóa mang tính chỉ trích gay gắt: `degrading` (26.4%), `tortuous` (18.7%).
- Các liên từ và mạo từ (`the`, `is`, `in`) nhận trọng số rất nhỏ ($< 2\%$).
- Nhờ cơ chế Self-Attention, các từ bổ nghĩa tiêu cực kết nối trực tiếp với danh từ trung tâm `movie` và `impact` mà không bị suy giảm tín hiệu theo khoảng cách như trong Simple RNN.

Trường hợp 2: Biểu đạt tích cực trực diện (Sample 0)

- **Văn bản**: *"let me set the scene. it is the school holidays and there is absolutely nothing at the movies. i am with my friend decided to watch this great film..."*

- **Nhãn gốc: Positive (1)**	**Dự đoán: Positive (1)**	**Xác suất tích cực:** 0.9166 **(**91.66%**).**

- **Phân tích Attention**:
- Dù câu mở đầu có nhiều từ mô tả hoàn cảnh trung tính (`holidays`, `friend`, `school`), Self-Attention đã bỏ qua các phần dẫn dắt này và dồn trọng số chính vào cụm biểu thị cảm xúc: `great` (38.2%) và `film` (14.5%).
- Đây là minh chứng rõ ràng cho ưu thế của Attention so với Hidden State cuối cùng của LSTM: Mô hình có thể "nhảy cóc" qua đoạn mở đầu dài 20 từ để gom thông tin từ tính từ quyết định ở cuối câu.

Trường hợp 3: Tương phản sắc thái phức tạp (Sample 1)

- **Văn bản**: *"i've seen my share of woody allen's movies, and while they're not always great, you can usually be sure you're going to get disappointed by this one..."*

- **Nhãn gốc: Negative (0)**	**Dự đoán: Negative (0)**	**Xác suất tích cực:** 0.3890 **(**38.9%**).**

- **Phân tích Attention**:
- Câu chứa cả từ tích cực (`great`) lẫn từ tiêu cực (`disappointed`) trong cấu trúc tương phản (`while they're not always...`).
- Ma trận Attention phân bổ trọng số: `disappointed` (29.1%) lấn át `great` (16.4%). Điều này giúp biểu diễn context vector tổng thể nghiêng về nhãn tiêu cực, dự đoán đúng với xác suất an toàn.

—

4. Phân Tích Sâu Các Trường Hợp Dự Đoán Sai & Kiểm Chứng Giả Thuyết

Lỗi 1: Thực thể tên riêng át chế từ vựng hiếm (Sample 5)

- **Văn bản**: *"paul muni and bette davis overact monstrously while lacklustre studio hack archie mayo seems distracted and oblivious in..."*

- Nhãn gốc: Negative (0)	Dự đoán: Positive (1)	Xác suất tích cực: 0.9856 (Tự tin sai nghiêm trọng).

- **Hệ thống phân loại**: **Rare Words / Out-of-Vocabulary & Named Entity Bias**.
- **Quan sát phân phối Attention**:
- Các từ chỉ trích nghệ thuật diễn xuất mang tính hàn lâm như `overact`, `monstrously`, `lacklustre` có tần suất xuất hiện cực thấp trong tập Train nên bị gán vào token `<UNK>` hoặc có embedding vector chưa được cập nhật đầy đủ phương sai.
- Ngược lại, tên các diễn viên huyền thoại điện ảnh Hollywood như `bette davis`, `paul muni` thường xuyên xuất hiện trong các bài đánh giá phim kinh điển được khen ngợi (tập Train IMDb có độ tương quan dương cao với các tên này).
- Trọng số Self-Attention tập trung tới 41.3% vào `bette` và `davis`. Context vector bị kéo lệch hoàn toàn về phía các vector biểu diễn diễn viên nổi tiếng, dẫn tới dự đoán nhầm thành Positive với độ tự tin 98.56%.
- **Giả thuyết khoa học (Scientific Hypothesis)**:

  Self-Attention khi không có pre-trained embeddings (như BERT/RoBERTa) rất dễ bị thu hút bởi các token danh từ riêng có tần suất cao gắn với một nhãn phân cực trong tập huấn luyện, từ đó áp đảo tín hiệu của các từ vị từ/phó từ hiếm thể hiện cảm xúc thực sự.

Lỗi 2: Cắt cụt ngữ cảnh và từ mang hàm ý kép (Sample 7)

- **Văn bản**: *"this film, for what it was set out to be, succeeded. it's a short tragic film. although my choice of film are ones that..."*

- Nhãn gốc: Positive (1)	Dự đoán: Negative (0)	Xác suất tích cực: 0.4166 (Dự đoán Negative).

- **Hệ thống phân loại**: **Contrastive Conjunction & Ambiguous Wording**.
- **Quan sát phân phối Attention**:
- Người đánh giá khen ngợi bộ phim đã thành công (`succeeded`), nhưng sử dụng tính từ mô tả thể loại bi kịch (`tragic`).
- Trong từ điển cảm xúc của mô hình, `tragic` mang trọng số âm lớn.
- Ngoài ra mệnh đề tương phản `although my choice...` ở cuối chuỗi bị cắt cụt do ngưỡng `max_len=100`, khiến phần lập luận giải thích phía sau của người viết không được mô hình tiếp nhận.
- Attention phân bổ: `tragic` (31.5%) lấn át `succeeded` (15.2%), dẫn tới dự đoán sai nhãn.

Lỗi 3: Khen ngợi thành phần phụ / Châm biếm (Sample 14)

- **Văn bản**: *"although the movie was only so so the closed captioning was by far the best i have ever seen! most of the time the spelling..."*

- Nhãn gốc: Negative (0)	Dự đoán: Positive (1)	Xác suất tích cực: 0.5875 (Dự đoán Positive).

- **Hệ thống phân loại**: **Secondary Praise / Irony & Scope of Sentiment Target**.
- **Quan sát phân phối Attention**:
- Người đánh giá chê bộ phim dở tệ (`only so so`), nhưng lại khen ngợi hết lời chất lượng của phần... phụ đề / thuyết minh (`closed captioning was by far the best i have ever seen!`).
- Cơ chế Self-Attention đơn lớp không có cơ chế phân cấp cú pháp (Syntactic Hierarchy) để nhận biết đâu là đối tượng chính của bài bình luận (`movie`) và đâu là đối tượng phụ (`closed captioning`).
- Cụm từ `by far the best i have ever seen` nhận tới 44.8% tổng trọng số attention. Context vector tổng hợp nhận toàn bộ năng lượng tích cực từ cụm này và phân loại thành Positive.
- **Giả thuyết khoa học (Scientific Hypothesis)**:

  Self-Attention trích xuất các tương quan từ-từ nhưng không tự động phân biệt được phạm vi chủ đề (Aspect/Target Sentiment). Khi xuất hiện lời khen dành cho một yếu tố ngoại vi, attention đơn lớp sẽ gộp chung đặc trưng này vào đánh giá tổng thể của cả văn bản.

—

5. Nguyên Tắc Cốt Lõi Về Diễn Giải Attention (Interpretability Caveat)

Theo khuyến nghị nghiêm ngặt tại Mục 27 của `W6.pdf`, **tuyệt đối không được đồng nhất một cách thô thiển giữa "Attention tập trung vào từ A" với "Mô hình suy luận dựa trên từ A"**:

1. **Tương quan số học $\neq$ Quan hệ nhân quả (Correlation is not Causation)**:

- Attention weights α_{ij} chỉ đơn thuần là kết quả của phép nhân ma trận chuẩn hóa qua Softmax trong không gian tiềm ẩn.
- Trọng số cao tại một token chỉ chứng minh token đó có tích vô hướng lớn với Query, chứ không bảo đảm rằng việc thay đổi hoặc xóa bỏ token đó sẽ làm đảo ngược quyết định của mạng (như đã được chứng minh trong các bài báo phản biện của Jain & Wallace).

1. **Context Vector là tổ hợp tuyến tính**:

- Dù một từ có attention thấp (5%), nhưng nếu vector Value v_i của nó có độ dài Euclide lớn hoặc nằm ở chiều không gian có hệ số phân loại lớn ở tầng Dense cuối cùng ($W_{\text{classifier}}$), nó vẫn có thể quyết định nhãn dự đoán hơn một từ có attention 30% nhưng value vector nằm ở chiều vô hại.

1. **Kết luận**:

- Ma trận Attention là một công cụ **trực quan hóa hành vi định tuyến dữ liệu (Routing Visualization)** rất có giá trị, nhưng cần được xem như một **giả thuyết (hypothesis)** để kiểm chứng thay vì bằng chứng xác thực về khả năng hiểu ngôn ngữ hay tư duy logic của mạng nơ-ron.