LAB 06 — ATTENTION MECHANISM: PRE-EXPERIMENT PREDICTIONS

Tài Liệu Phân Tích & Thực Nghiệm Khoa Học

October 25, 2026

Môn học: Xử lý ngôn ngữ tự nhiên và ứng dụng
Học kỳ: Học kỳ I - 2026
Chủ đề: From Recurrent State to Context-Aware Representation
Thời điểm khóa dự đoán: TRƯỚC KHI CHẠY THỰC NGHIỆM MÔ HÌNH VÀ CODE
—

1. Tuyên Bố Quy Trình Khoa Học (Scientific Protocol)

Bản tài liệu này chứa các dự đoán và giả thuyết khoa học được lập ra và **khóa cứng trước khi thực thi bất kỳ đoạn mã huấn luyện hoặc kiểm thử nào** trong `self_attention.ipynb` và `attention_numpy.py`. Toàn bộ các suy luận được xây dựng dựa trên bản chất đại số tuyến tính của tích vô hướng, hàm chuẩn hóa Softmax, tính chất gradient của phép chiếu tuyến tính và động học của cơ chế Self-Attention so với mạng hồi quy tuần tự (LSTM ở LAB 05).
—

2. Danh Sách 5 Dự Đoán Lý Thuyết Cốt Lõi (Mục 12 - W6.pdf)

Dự đoán 1: Tác động của Dot Product lớn hơn lên Attention Weight

- **Câu hỏi / Tình huống**: Nếu một key có tích vô hướng (dot product) với query lớn hơn rõ rệt so với các key khác trong cùng một chuỗi, attention weight của key đó sẽ biến thiên như thế nào?
- **Prediction**: Attention weight tương ứng với key đó sẽ tăng vọt phi tuyến tính và chiếm tỷ trọng chi phối gần như toàn bộ phân phối xác suất chú ý (tiệm cận mức cực đại ≈ 1.0).
- **Reason (Lý giải khoa học)**:
- Hàm Softmax sử dụng hàm mũ tự nhiên $f(z) = e^z$ trên từng score $s_i = q^T k_i$.
- Đạo hàm bậc một $f'(z) = e^z > 0$ và đạo hàm bậc hai $f''(z) = e^z > 0$ đều dương trên toàn miền số thực $\mathbb{R}$, nghĩa là hàm mũ tăng trưởng siêu tuyến tính (convex function).
- Khoảng cách số học tuyến tính giữa điểm cao nhất và điểm kế tiếp sẽ bị khuếch đại theo hàm mũ cơ số e. Khi chia cho tổng mẫu số $\sum_j e^{s_j}$, trọng số của key có tích vô hướng lớn nhất sẽ bỏ xa các phần tử còn lại, dẫn tới hiện tượng ”winner-take-most” (kẻ thắng thâu tóm phần lớn trọng số).
- **Confidence**: Cao (99%).
- **Tiêu chí kiểm chứng (Verification Criteria)**: Kiểm chứng qua hàm `scaled_dot_product_attention` trên vector điểm số có thành phần vượt trội so với các thành phần còn lại.

—

Dự đoán 2: Hành vi của Attention Weight khi tất cả Scores bằng nhau

- **Câu hỏi / Tình huống**: Nếu tất cả các key đều có cùng một giá trị tích vô hướng với query, cụ thể với vector điểm số $s = [1, 1, 1, 1]$, các attention weights tương ứng sẽ phân bổ ra sao?
- **Prediction**: Toàn bộ các attention weights sẽ hoàn toàn bằng nhau và tạo thành một phân phối đều (Uniform Distribution) lý tưởng:

$$\alpha = \left[\frac{1}{4}, \frac{1}{4}, \frac{1}{4}, \frac{1}{4}\right] = [0.25, 0.25, 0.25, 0.25]$$

- **Reason (Lý giải khoa học)**:

- Nếu $s_1 = s_2 = \cdots = s_N = c$, thì $\exp(s_i) = e^c, \forall i \in \{1, \ldots, N\}$.
- Mẫu số của softmax là tổng của N số hạng bằng nhau:

$$\sum_{j=1}^{N} \exp(s_j) = N \cdot e^c$$

- Khi đó trọng số của mỗi phần tử là:

$$\alpha_i = \frac{e^c}{N \cdot e^c} = \frac{1}{N}$$

- Giá trị c bị triệt tiêu hoàn toàn; phân phối đạt cực đại về entropy thông tin ($H = \ln 4 \approx 1.3863$).
- **Confidence**: Tuyệt đối (100%).
- **Tiêu chí kiểm chứng (Verification Criteria)**: Kiểm tra trực tiếp bằng script tính Softmax trên vector $s = [1, 1, 1, 1]$.

—

Dự đoán 3: Mức độ tập trung khi một Score vượt trội cực lớn

- **Câu hỏi / Tình huống**: Nếu một điểm số lớn hơn rất nhiều so với các điểm số khác trong chuỗi, cụ thể với vector $s = [1, 1, 10]$, attention weights sẽ tập trung như thế nào?
- **Prediction**: Attention sẽ rơi vào trạng thái bão hòa cực độ (Hard Attention collapse), trong đó token thứ 3 nhận trên 99.99% trọng số chú ý, biến các token còn lại thành các giá trị không đáng kể ($< 0.01\%$).
- **Reason (Lý giải khoa học)**:
- Giá trị mũ của các phần tử:
- $e^1 \approx 2.71828$
- $e^{10} \approx 22026.46579$
- Tổng mẫu số:

$$Z = 2.71828 + 2.71828 + 22026.46579 \approx 22031.90235$$

- Trọng số tương ứng:

$$\alpha_3 = \frac{22026.46579}{22031.90235} \approx 0.999753 \approx 99.98\%$$

$$\alpha_1 = \alpha_2 \approx \frac{2.71828}{22031.90235} \approx 0.000123 \approx 0.01\%$$

- Chênh lệch điểm số là 9 đơn vị đã khiến tỉ lệ xác suất chênh lệch tới $e^9 \approx 8103$ lần. Kết quả là context vector sẽ hầu như trùng khít với value vector v_3.
- **Confidence**: Tuyệt đối (100%).
- **Tiêu chí kiểm chứng (Verification Criteria)**: Tính Softmax số học trên vector $[1, 1, 10]$ trong `self_attention.ipynb`.

—

Dự đoán 4: Biến thiên chi phí tính toán khi chiều dài chuỗi tăng 100 lần

- **Câu hỏi / Tình huống**: Nếu chiều dài chuỗi token tăng từ $T_1 = 10$ tokens lên $T_2 = 1000$ tokens (tăng gấp 100 lần), chi phí tính toán và bộ nhớ của ma trận attention sẽ thay đổi như thế nào?
- **Prediction**: Chi phí thời gian tính toán và dung lượng bộ nhớ lưu ma trận attention sẽ không tăng tuyến tính 100 lần mà sẽ tăng vọt theo hàm bậc hai đúng $10,000$ lần (100^2).
- **Reason (Lý giải khoa học)**:
- Ma trận Attention trong self-attention có kích thước $T \times T$ vì mỗi token cần tính tích vô hướng với mọi token khác trong chuỗi (kể cả chính nó).

- Với $T_1 = 10$, ma trận có $10 \times 10 = 100$ phần tử.
- Với $T_2 = 1000$, ma trận có $1000 \times 1000 = 1,000,000$ phần tử.
- Tỉ lệ số phép tính và kích thước lưu trữ là:

$$\frac{T_2^2}{T_1^2} = \left(\frac{1000}{10}\right)^2 = 100^2 = 10,000 \text{ lần}$$

- Trong khi đó mô hình RNN chỉ tăng chi phí tuyến tính $O(T)$, tức tăng đúng 100 lần. Đây chính là nút thắt cổ chai bậc hai $O(T^2)$ của Self-Attention chuẩn.
- **Confidence**: Tuyệt đối (100%).
- **Tiêu chí kiểm chứng (Verification Criteria)**: Đo đạc số lượng phép toán và thời gian tính toán của hàm self-attention khi tăng kích thước chuỗi từ 10 đến 1000.

—

Dự đoán 5: Attention có luôn chọn đúng token mà con người đánh giá là quan trọng nhất?

- **Câu hỏi / Tình huống**: Attention weights có luôn luôn tập trung cao nhất vào các từ khóa mang tải ngữ nghĩa hoặc từ loại quan trọng nhất theo cảm quan ngữ pháp của con người không?
- **Prediction**: **KHÔNG LUÔN LUÔN ĐÚNG**. Attention phân phối trọng số theo tối ưu hóa hàm mất mát (loss function) của bài toán cụ thể và không gian embedding, chứ không tự động trùng khớp với cấu trúc cú pháp hay nhận thức ngữ nghĩa trực quan của con người.
- **Reason (Lý giải khoa học)**:
- Attention weights α_{ij} phản ánh mức độ tương đồng giữa các vector chiếu q_i và k_j. Các vector này chịu sự dẫn dắt của gradient lan truyền ngược nhằm giảm thiểu sai số phân loại cuối cùng.
- Mô hình có thể chú ý mạnh vào các dấu câu (dấu chấm, dấu phẩy), từ dừng (stop words) hoặc các vị trí padding nếu các vị trí này vô tình tích lũy thông tin bias hoặc đóng vai trò như một bộ nhớ đệm (scratchpad memory) trung gian.
- Nhiều nghiên cứu kinh điển trong NLP (như *Jain & Wallace, 2019 "Attention is not Explanation"* hay *Wiegreffe & Pinter, 2019 "Attention is not not Explanation"*) đã chỉ ra rằng các trọng số attention khác nhau có thể cho ra cùng một kết quả dự đoán, do đó ma trận attention là bằng chứng về phân phối số học, không tự động là lời giải thích nhân quả (causal reasoning) theo ngôn ngữ học.
- **Confidence**: Rất cao (95%).
- **Tiêu chí kiểm chứng (Verification Criteria)**: Quan sát trực quan qua bản đồ nhiệt Attention Heatmap trên các câu ví dụ cụ thể trong thực nghiệm (`Experiment 3` và `Experiment 4`).

—

3. Dự Đoán Cho Thực Nghiệm Phân Loại Cảm Xúc (IMDb Sentiment Task)

Dự đoán 6: So sánh Self-Attention Classifier với LSTM (Baseline LAB 05)

- **Câu hỏi / Tình huống**: So sánh mô hình `Embedding + Self-Attention + Linear Classifier` với mô hình `Embedding + LSTM + Classifier` (từ LAB 05) trên tập dữ liệu IMDb khi cùng giới hạn độ dài chuỗi ($T = 100$) và số epoch.
- **Prediction**:

1. **Tốc độ huấn luyện**: Self-Attention sẽ có tốc độ huấn luyện nhanh hơn hoặc tương đương trên mỗi epoch so với LSTM nhờ khả năng xử lý song song toàn bộ ma trận chuỗi, thay vì phải chạy vòng lặp tuần tự qua 100 bước thời gian như LSTM.

1. **Khả năng nắm bắt tương tác**: Self-Attention sẽ dễ dàng kết nối trực tiếp các từ chỉ cảm xúc cách xa nhau (như *"good despite ... slow beginning"*) trong khi LSTM phụ thuộc vào việc nén thông tin qua trạng thái ẩn h_t và cell state c_t.

1. **Độ chính xác (Accuracy / F1)**: Khi huấn luyện từ đầu (train from scratch) trên tập mẫu nhỏ mà không có pre-trained embeddings hay positional encoding, Self-Attention có thể gặp hiện tượng không phân biệt được trật tự từ nếu không bổ sung vị trí, dẫn tới độ chính xác có thể xấp xỉ hoặc nhỉnh hơn nhẹ so với LSTM đơn giản, nhưng vượt trội ở khả năng giải thích trực quan qua bản đồ chú ý.

- **Tiêu chí kiểm chứng (Verification Criteria)**: Bảng số liệu đối chiếu trong `results.csv` và ma trận nhầm lẫn `confusion_matrix.png`.