BÀI TẬP TÍNH TOÁN BẰNG TAY — TRANSFORMER ARCHITECTURE

Tài Liệu Phân Tích & Thực Nghiệm Khoa Học

November 4, 2026

Môn học: Xử lý ngôn ngữ tự nhiên và ứng dụng
Học kỳ: Học kỳ I - 2026
Chủ đề: From Attention to Transformer
Sinh viên thực hiện: Nguyễn Văn Thành
Hạn nộp: 23:59 - 04/11/2026
—

1. Bài Toán 1: Tính Toán Chi Tiết Một Attention Head và Multi-Head Concatenation

1.1. Mục tiêu và Bối cảnh

Bài toán nhằm minh họa tường minh cơ chế biến đổi đại số tuyến tính bên trong một attention head (Section 6 & 7 trong đề bài `W7.pdf`), từ các ma trận chiếu đầu vào, tích vô hướng thu phóng (scaled dot-product), phân phối trọng số Softmax, đến việc tổng hợp vector ngữ cảnh và ghép nối đa đầu (multi-head concatenation).

1.2. Dữ kiện đầu vào và Giả thiết

Cho chuỗi đầu vào gồm $T = 3$ token, mỗi token được biểu diễn bằng vector embedding có số chiều $d_{model} = 4$:

$$X = \begin{bmatrix} 1 & 0 & 1 & 0 \\ 0 & 2 & 0 & 1 \\ 1 & 1 & 0 & 0 \end{bmatrix} \in \mathbb{R}^{3\times 4}$$

Giả sử chiều không gian của một head là $d_k = 2$. Các ma trận trọng số chiếu tuyến tính của Head 1 gồm $W_1^Q, W_1^K, W_1^V \in \mathbb{R}^{4\times 2}$ được cho như sau:

$$W_1^Q = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 1 \\ 1 & 0 \end{bmatrix}, \quad W_1^K = \begin{bmatrix} 0 & 1 \\ 1 & 0 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}, \quad W_1^V = \begin{bmatrix} 1 & 1 \\ 0 & 1 \\ 1 & 0 \\ 0 & 2 \end{bmatrix}$$

Hệ số thu phóng (scaling factor): $\sqrt{d_k} = \sqrt{2} \approx 1.41421$.
—

1.3. Các Bước Biến Đổi Trung Gian Cho Head 1

Bước 1: Tính ma trận Query (Q), Key (K), Value (V) Thực hiện phép nhân ma trận $Q = XW_1^Q$:

$$Q = \begin{bmatrix} 1 & 0 & 1 & 0 \\ 0 & 2 & 0 & 1 \\ 1 & 1 & 0 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 1 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} 1\cdot 1+0\cdot 0+1\cdot 0+0\cdot 1 & 1\cdot 0+0\cdot 1+1\cdot 1+0\cdot 0 \\ 0\cdot 1+2\cdot 0+0\cdot 0+1\cdot 1 & 0\cdot 0+2\cdot 1+0\cdot 1+1\cdot 0 \\ 1\cdot 1+1\cdot 0+0\cdot 0+0\cdot 1 & 1\cdot 0+1\cdot 1+0\cdot 1+0\cdot 0 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 1 \end{bmatrix}$$

Thực hiện phép nhân ma trận $K = XW_1^K$:

$$K = \begin{bmatrix} 1 & 0 & 1 & 0 \\ 0 & 2 & 0 & 1 \\ 1 & 1 & 0 & 0 \end{bmatrix} \begin{bmatrix} 0 & 1 \\ 1 & 0 \\ 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1\cdot 0+0\cdot 1+1\cdot 1+0\cdot 0 & 1\cdot 1+0\cdot 0+1\cdot 0+0\cdot 1 \\ 0\cdot 0+2\cdot 1+0\cdot 1+1\cdot 0 & 0\cdot 1+2\cdot 0+0\cdot 0+1\cdot 1 \\ 1\cdot 0+1\cdot 1+0\cdot 1+0\cdot 0 & 1\cdot 1+1\cdot 0+0\cdot 0+0\cdot 1 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 2 & 1 \\ 1 & 1 \end{bmatrix}$$

Thực hiện phép nhân ma trận $V = XW_1^V$:

$$V = \begin{bmatrix} 1 & 0 & 1 & 0 \\ 0 & 2 & 0 & 1 \\ 1 & 1 & 0 & 0 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 0 & 1 \\ 1 & 0 \\ 0 & 2 \end{bmatrix} = \begin{bmatrix} 1\cdot1+0\cdot0+1\cdot1+0\cdot0 & 1\cdot1+0\cdot1+1\cdot0+0\cdot2 \\ 0\cdot1+2\cdot0+0\cdot0+1\cdot0 & 0\cdot1+2\cdot1+0\cdot0+1\cdot2 \\ 1\cdot1+1\cdot0+0\cdot1+0\cdot0 & 1\cdot1+1\cdot1+0\cdot0+0\cdot2 \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ 0 & 4 \\ 1 & 2 \end{bmatrix}$$

Bước 2: Tính tích vô hướng tương đồng QK^T Chuyển vị ma trận K:

$$K^T = \begin{bmatrix} 1 & 2 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

Nhân ma trận $QK^T \in \mathbb{R}^{3\times3}$:

$$QK^T = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 & 1 \\ 1 & 1 & 1 \end{bmatrix} = \begin{bmatrix} 1\cdot1+1\cdot1 & 1\cdot2+1\cdot1 & 1\cdot1+1\cdot1 \\ 1\cdot1+2\cdot1 & 1\cdot2+2\cdot1 & 1\cdot1+2\cdot1 \\ 1\cdot1+1\cdot1 & 1\cdot2+1\cdot1 & 1\cdot1+1\cdot1 \end{bmatrix} = \begin{bmatrix} 2 & 3 & 2 \\ 3 & 4 & 3 \\ 2 & 3 & 2 \end{bmatrix}$$

Bước 3: Thu phóng tỉ lệ bằng $\sqrt{d_k} = \sqrt{2} \approx 1.41421$

$$S = \frac{QK^T}{\sqrt{2}} = \begin{bmatrix} \frac{2}{\sqrt{2}} & \frac{3}{\sqrt{2}} & \frac{2}{\sqrt{2}} \\ \frac{3}{\sqrt{2}} & \frac{4}{\sqrt{2}} & \frac{3}{\sqrt{2}} \\ \frac{2}{\sqrt{2}} & \frac{3}{\sqrt{2}} & \frac{2}{\sqrt{2}} \end{bmatrix} \approx \begin{bmatrix} 1.41421 & 2.12132 & 1.41421 \\ 2.12132 & 2.82843 & 2.12132 \\ 1.41421 & 2.12132 & 1.41421 \end{bmatrix}$$

Bước 4: Chuẩn hóa phân phối xác suất qua hàm Softmax Áp dụng Softmax ổn định số học theo từng hàng của ma trận S:

Xét hàng 1: $s_1 = [1.41421, 2.12132, 1.41421]$.
Giá trị cực đại $m_1 = 2.12132$.
Các số mũ:

- $\exp(1.41421 - 2.12132) = \exp(-0.70711) \approx 0.49307$
- $\exp(2.12132 - 2.12132) = \exp(0) = 1.00000$
- $\exp(1.41421 - 2.12132) = \exp(-0.70711) \approx 0.49307$

Tổng số mũ: $\sum = 0.49307 + 1.00000 + 0.49307 = 1.98614$.
Trọng số Attention hàng 1:

- $a_{11} = \frac{0.49307}{1.98614} \approx 0.24826$
- $a_{12} = \frac{1.00000}{1.98614} \approx 0.50349$
- $a_{13} = \frac{0.49307}{1.98614} \approx 0.24826$

Xét hàng 2: $s_2 = [2.12132, 2.82843, 2.12132]$.
Giá trị cực đại $m_2 = 2.82843$.
Các hiệu số $s_{2j} - m_2$ chính xác bằng $[-0.70711, 0, -0.70711]$, hoàn toàn trùng khớp với hàng 1!
Do đó phân phối xác suất hàng 2 và hàng 3 giống hệt hàng 1:

$$A = \text{softmax}(S) = \begin{bmatrix} 0.24826 & 0.50349 & 0.24826 \\ 0.24826 & 0.50349 & 0.24826 \\ 0.24826 & 0.50349 & 0.24826 \end{bmatrix}$$

Bước 5: Tính đầu ra của Head 1 ($Z_1 = AV$)

$$Z_1 = \begin{bmatrix} 0.24826 & 0.50349 & 0.24826 \\ 0.24826 & 0.50349 & 0.24826 \\ 0.24826 & 0.50349 & 0.24826 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 0 & 4 \\ 1 & 2 \end{bmatrix}$$

Với mỗi hàng của Z_1:

- Cột 1: $0.24826 \cdot 2 + 0.50349 \cdot 0 + 0.24826 \cdot 1 = 0.49652 + 0 + 0.24826 = 0.74478$
- Cột 2: $0.24826 \cdot 1 + 0.50349 \cdot 4 + 0.24826 \cdot 2 = 0.24826 + 2.01396 + 0.49652 = 2.75874$

Kết quả đầu ra của Head 1:

$$\text{head}_1 = Z_1 = \begin{bmatrix} 0.74478 & 2.75874 \\ 0.74478 & 2.75874 \\ 0.74478 & 2.75874 \end{bmatrix} \in \mathbb{R}^{3\times 2}$$

—

1.4. Ghép Nối Đa Đầu (Multi-Head Concatenation) và Chiếu Tuyến Tính W^O

Giả sử hệ thống có $h = 2$ attention heads ($d_k = 2$, tổng chiều là $h \cdot d_k = 4 = d_{model}$).

Đầu ra của Head 2 sau các phép tính độc lập (với bộ trọng số W_2^Q, W_2^K, W_2^V) thu được ma trận:

$$\text{head}_2 = Z_2 = \begin{bmatrix} 2.18210 & 1.32716 \\ 1.33333 & 1.66667 \\ 1.75872 & 1.49651 \end{bmatrix} \in \mathbb{R}^{3\times 2}$$

Thực hiện ghép nối (Concatenation) dọc theo chiều đặc trưng:

$$\text{Concat}(\text{head}_1, \text{head}_2) = \begin{bmatrix} 0.74478 & 2.75874 & 2.18210 & 1.32716 \\ 0.74478 & 2.75874 & 1.33333 & 1.66667 \\ 0.74478 & 2.75874 & 1.75872 & 1.49651 \end{bmatrix} \in \mathbb{R}^{3\times 4}$$

Cho ma trận chiếu đầu ra $W^O \in \mathbb{R}^{4\times 4}$:

$$W^O = \begin{bmatrix} 1.0 & 0.0 & 1.0 & 0.0 \\ 0.0 & 1.0 & 0.0 & 1.0 \\ 0.5 & 0.0 & 0.5 & 0.0 \\ 0.0 & 0.5 & 0.0 & 0.5 \end{bmatrix}$$

Nhân ma trận kết thúc Multi-Head Attention:

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \text{head}_2) \cdot W^O = \begin{bmatrix} 1.83583 & 3.42232 & 1.83583 & 3.42232 \\ 1.41145 & 3.59208 & 1.41145 & 3.59208 \\ 1.62414 & 3.50700 & 1.62414 & 3.50700 \end{bmatrix} \in \mathbb{R}^{3\times 4}$$

1.5. Trả Lời Câu Hỏi Cốt Lõi (Section 7)

Câu hỏi: *Vì sao cần concatenation trước khi áp dụng W^O?*

Trả lời:

1. **Phân tách không gian biểu diễn (Subspace Separation)**: Mỗi attention head học chiếu câu văn vào một không gian con độc lập (ví dụ một head học cú pháp vị ngữ - chủ ngữ, head khác học quan hệ thực thể - đại từ hoặc phủ định). Các head này tạo ra các biểu diễn có ngữ nghĩa khác nhau.

1. **Tổng hợp đa thông tin không làm mất mát (Non-destructive aggregation)**: Nếu ta cộng trực tiếp các head lại với nhau ($\text{head}_1 + \text{head}_2$), các đặc trưng sẽ bị triệt tiêu hoặc hòa lẫn trước khi mô hình học được trọng số kết hợp. Phép ghép nối Concat giữ nguyên vẹn toàn bộ thông tin độc lập của cả h heads.

1. **Pha trộn tuyến tính linh hoạt qua W^O**: Khi nhân ma trận $W^O \in \mathbb{R}^{(h \cdot d_k) \times d_{model}}$, mạng nơ-ron có thể tự do học cách lấy tổ hợp tuyến tính kết nối giữa kênh i của Head 1 với kênh j của Head 2, khôi phục lại không gian biểu diễn chuẩn d_{model} để truyền vào khối Residual tiếp theo.

—

2. Bài Toán 2: Tính Toán Chi Tiết Sinusoidal Positional Encoding

2.1. Mục tiêu và Công thức Chuẩn

Để bù đắp việc Self-Attention có tính chất hoán vị bất biến (permutation invariant), Transformer bổ sung thông tin vị trí thông qua các sóng sin và cos ở nhiều tần số khác nhau:

$$PE(pos, 2i) = \sin\left(\frac{pos}{10000^{\frac{2i}{d}}}\right), \quad PE(pos, 2i+1) = \cos\left(\frac{pos}{10000^{\frac{2i}{d}}}\right)$$

Trong đó:

- $pos \in \{0, 1, 2, \ldots, T-1\}$ là chỉ số vị trí của token trong chuỗi.
- $i \in \{0, 1, \ldots, \frac{d}{2} - 1\}$ là chỉ số cặp chiều đặc trưng.
- $d = d_{model}$ là số chiều embedding của mô hình.

2.2. Dữ kiện bài toán (Section 10 trong W7.pdf)

- Kích thước embedding: $d = 4$.
- Các vị trí cần tính: $pos = 0, 1, 2$.

Với $d = 4$, ta có $i \in \{0, 1\}$ ứng với 4 chiều:

1. Với $i = 0$ (chiều 0 và 1):

$$\lambda_0 = 10000^{\frac{2 \cdot 0}{4}} = 10000^0 = 1.0$$

Chu kỳ bước sóng: $T_0 = 2\pi \cdot 1 \approx 6.28$ tokens.

1. Với $i = 1$ (chiều 2 và 3):

$$\lambda_1 = 10000^{\frac{2 \cdot 1}{4}} = 10000^{0.5} = \sqrt{10000} = 100.0$$

Chu kỳ bước sóng: $T_1 = 2\pi \cdot 100 \approx 628.32$ tokens.

—

2.3. Các Bước Tính Toán Tường Minh

Vị trí $pos = 0$:

- Chiều 0 ($2i = 0$): $PE(0, 0) = \sin\left(\frac{0}{1}\right) = \sin(0) = 0.00000$
- Chiều 1 ($2i + 1 = 1$): $PE(0, 1) = \cos\left(\frac{0}{1}\right) = \cos(0) = 1.00000$
- Chiều 2 ($2i = 2$): $PE(0, 2) = \sin\left(\frac{0}{100}\right) = \sin(0) = 0.00000$
- Chiều 3 ($2i + 1 = 3$): $PE(0, 3) = \cos\left(\frac{0}{100}\right) = \cos(0) = 1.00000$

$$PE(0) = \begin{bmatrix} 0.00000 & 1.00000 & 0.00000 & 1.00000 \end{bmatrix}^T$$

Vị trí $pos = 1$:

- Chiều 0 ($2i = 0$): $PE(1, 0) = \sin\left(\frac{1}{1}\right) = \sin(1 \text{ rad}) \approx 0.84147$
- Chiều 1 ($2i + 1 = 1$): $PE(1, 1) = \cos\left(\frac{1}{1}\right) = \cos(1 \text{ rad}) \approx 0.54030$
- Chiều 2 ($2i = 2$): $PE(1, 2) = \sin\left(\frac{1}{100}\right) = \sin(0.01 \text{ rad}) \approx 0.0099998 \approx 0.01000$
- Chiều 3 ($2i + 1 = 3$): $PE(1, 3) = \cos\left(\frac{1}{100}\right) = \cos(0.01 \text{ rad}) \approx 0.99995$

$$PE(1) = \begin{bmatrix} 0.84147 & 0.54030 & 0.01000 & 0.99995 \end{bmatrix}^T$$

Vị trí $pos = 2$:

- Chiều 0 ($2i = 0$): $PE(2, 0) = \sin\left(\frac{2}{1}\right) = \sin(2 \text{ rad}) \approx 0.90930$
- Chiều 1 ($2i + 1 = 1$): $PE(2, 1) = \cos\left(\frac{2}{1}\right) = \cos(2 \text{ rad}) \approx -0.41615$
- Chiều 2 ($2i = 2$): $PE(2, 2) = \sin\left(\frac{2}{100}\right) = \sin(0.02 \text{ rad}) \approx 0.019999 \approx 0.02000$
- Chiều 3 ($2i + 1 = 3$): $PE(2, 3) = \cos\left(\frac{2}{100}\right) = \cos(0.02 \text{ rad}) \approx 0.99980$

$$PE(2) = \begin{bmatrix} 0.90930 & -0.41615 & 0.02000 & 0.99980 \end{bmatrix}^T$$

—

2.4. Bảng Ma Trận Positional Encoding Tổng Hợp

$$PE = \begin{bmatrix} 0.00000 & 1.00000 & 0.00000 & 1.00000 \\ 0.84147 & 0.54030 & 0.01000 & 0.99995 \\ 0.90930 & -0.41615 & 0.02000 & 0.99980 \end{bmatrix} \in \mathbb{R}^{3\times 4}$$

2.5. Sanity Check và Ý Nghĩa Khoa Học

1. **Kiểm tra chuẩn biên độ**:

- Ở cặp chiều thứ nhất ($i = 0$): $\sin^2(pos) + \cos^2(pos) = 1$ với mọi pos. Cụ thể:

$pos = 0 : 0^2 + 1^2 = 1.0$;
$pos = 1 : 0.84147^2 + 0.54030^2 = 0.70807 + 0.29192 = 0.99999 \approx 1.0$;
$pos = 2 : 0.90930^2 + (-0.41615)^2 = 0.82683 + 0.17318 = 1.00001 \approx 1.0$.

- Ở cặp chiều thứ hai ($i = 1$): $\sin^2(pos/100) + \cos^2(pos/100) = 1$ với mọi pos.

1. **Khả năng phân biệt vị trí**: Vector $PE(pos)$ ở mỗi vị trí là độc nhất (unique). Tần số cao ở các chiều đầu thay đổi liên tục giúp nhận biết các vị trí gần nhau, trong khi tần số thấp ở các chiều sau thay đổi chậm rãi giúp mã hóa khoảng cách vị trí tầm xa.

—

3. Bài Toán 3: Tính Toán Chi Tiết Position-Wise Feed-Forward Network (FFN)

3.1. Mục tiêu và Công thức

Khối Feed-Forward Network áp dụng độc lập và đồng nhất lên từng vị trí của chuỗi (position-wise):

$$FFN(x) = W_2 \cdot \sigma(W_1 x + b_1) + b_2$$

Trong đó $\sigma(\cdot)$ là hàm kích hoạt phi tuyến (ReLU: $\text{ReLU}(z) = \max(0, z)$).

3.2. Dữ kiện bài toán (Section 14 trong W7.pdf)

Cho vector biểu diễn đầu vào tại một vị trí:

$$x = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \in \mathbb{R}^{2\times 1}$$

Ma trận trọng số và bias tầng thứ nhất:

$$W_1 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \quad b_1 = \begin{bmatrix} 0 \\ -1 \end{bmatrix}$$

Cho ma trận chiếu và bias tầng thứ hai để hoàn chỉnh toàn bộ FFN:

$$W_2 = \begin{bmatrix} 2 & -1 \\ 1 & 3 \end{bmatrix}, \quad b_2 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

—

3.3. Các Bước Tính Toán Tường Minh

Bước 1: Tính giá trị trước hàm kích hoạt (Pre-activation z_1)

$$z_1 = W_1 x + b_1 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \end{bmatrix} + \begin{bmatrix} 0 \\ -1 \end{bmatrix} = \begin{bmatrix} 1 \cdot 1 + 0 \cdot 2 \\ 0 \cdot 1 + 1 \cdot 2 \end{bmatrix} + \begin{bmatrix} 0 \\ -1 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \end{bmatrix} + \begin{bmatrix} 0 \\ -1 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

Bước 2: Kích hoạt phi tuyến ReLU (h)

$$h = \text{ReLU}(z_1) = \text{ReLU}\left(\begin{bmatrix} 1 \\ 1 \end{bmatrix} \right) = \begin{bmatrix} \max(0,1) \\ \max(0,1) \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

Bước 3: Chiếu tuyến tính tầng thứ hai (y)

$$y = W_2 h + b_2 = \begin{bmatrix} 2 & -1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} + \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 2 \cdot 1 + (-1) \cdot 1 \\ 1 \cdot 1 + 3 \cdot 1 \end{bmatrix} + \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 1 \\ 4 \end{bmatrix} + \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 2 \\ 4 \end{bmatrix}$$

3.4. Sanity Check và Ý Nghĩa Cốt Lõi

1. **Kiểm tra tính phi tuyến**: Nhờ có hàm ReLU, nếu $x_2 \leq 1$ thì $z_{1,2} \leq 0 \Rightarrow h_2 = 0$, mạch nơ-ron thực hiện phép ngắt ngưỡng.

1. **Vai trò của FFN trong Transformer Block**: Attention là phép tương tác **ngang** giữa các vị trí trong chuỗi (token mixing). FFN là phép biến đổi phi tuyến **dọc** theo từng vị trí (channel mixing), cho phép trích xuất các tổ hợp đặc trưng trừu tượng mà phép tổ hợp tuyến tính trong attention không làm được.

—

4. Bài Toán 4: Theo Dõi Kích Thước Tensor (Shape Trace) Qua Toàn Bộ Transformer Encoder Block

4.1. Thiết lập tham số (Section 18 trong W7.pdf)

- Kích thước batch: $B = 8$
- Chiều dài chuỗi: $T = 100$
- Kích thước mô hình: $d_{model} = 128$
- Số attention heads: $n_{heads} = 4$
- Chiều không gian của mỗi head: $d_k = \frac{d_{model}}{n_{heads}} = \frac{128}{4} = 32$
- Chiều ẩn của FFN: $d_{ff} = 4 \times d_{model} = 512$

—

4.2. Bảng Theo Dõi Shape Từng Bước (Full Forward Shape Trace)

Bước thực thi	Tensor đại diện	Ký hiệu toán học / Phép biến đổi	Kích thước Tensor (Shape)	Diễn giải kỹ thuật
0. Đầu vào	X	Input Embeddings + PE	`(8, 100, 128)`	$B = 8$ câu, mỗi câu $T = 100$ tokens, vector $d = 128$.
1. Chiếu Q, K, V	Q, K, V	$X \cdot W^Q, X \cdot W^K, X \cdot W^V$	`(8, 100, 128)`	Từng ma trận có trọng số `(128, 128)`.
2. Tách Multi-Head	$Q_{split}, K_{split}, V_{split}$	Reshape `(B, T, h, dk)` $\rightarrow$ Permute	`(8, 4, 100, 32)`	$h = 4$ heads song song, mỗi head $d_k = 32$.
3. Attention Scores	$Scores$	$\frac{Q \cdot K^T}{\sqrt{d_k}}$	`(8, 4, 100, 100)`	Ma trận tương tác giữa T tokens với nhau: 100×100.
4. Attention Weights	A	Softmax$(Scores, \text{dim} = -1)$	`(8, 4, 100, 100)`	Tổng mỗi hàng bằng 1 (xác suất chú ý).
5. Context Matrix	$Context$	$A \cdot V$	`(8, 4, 100, 32)`	Tổng hợp thông tin từ V theo phân phối A.
6. Ghép Heads	$Concat$	Permute $\rightarrow$ Reshape `(B, T, h*dk)`	`(8, 100, 128)`	Ghép nối 4 heads thành vector chiều 128 ban đầu.
7. Chiếu đầu ra MHA	MHA_{out}	$Concat \cdot W^O$	`(8, 100, 128)`	Chiếu tuyến tính qua $W^O \in \mathbb{R}^{128 \times 128}$.
8. Residual 1	X_1	$X + MHA_{out}$	`(8, 100, 128)`	Kết nối tắt bảo tồn thông tin đầu vào.
9. LayerNorm 1	$\tilde{X}_1$	LayerNorm(X_1)	`(8, 100, 128)`	Chuẩn hóa theo chiều cuối ($d_{model} = 128$).
10. FFN Tầng 1	H_{ffn}	ReLU$(\tilde{X}_1 \cdot W_1 + b_1)$	`(8, 100, 512)`	Mở rộng không gian đặc trưng lên $d_{ff} = 512$.
11. FFN Tầng 2	FFN_{out}	$H_{ffn} \cdot W_2 + b_2$	`(8, 100, 128)`	Thu hẹp về kích thước chuẩn $d_{model} = 128$.
12. Residual 2	X_2	$\tilde{X}_1 + FFN_{out}$	`(8, 100, 128)`	Kết nối tắt khối FFN.
13. LayerNorm 2	$Output$	LayerNorm(X_2)	`(8, 100, 128)`	Đầu ra hoàn chỉnh của Transformer Block.

—

4.3. Các Lưu Ý Về Lỗi Shape Phổ Biến Cần Tránh

1. **Lỗi thứ tự trục khi tính Attention**: Nếu quên hoán vị trục (permute) mà reshape trực tiếp từ `(8, 100, 128)` sang `(8, 4, 100, 32)`, các token sẽ bị trộn lẫn vào các head thay vì phân tách theo chiều đặc trưng.

Thứ tự đúng bắt buộc là: `reshape(8, 100, 4, 32).transpose(1, 2)`.

1. **Chi phí bộ nhớ bậc hai** $O(T^2)$: Tensor Attention Scores chiếm kích thước `(8, 4, 100, 100)` tức $8 \times 4 \times 100 \times 100 = 320,000$ phần tử float32. Nếu chuỗi tăng lên $T = 1000$, số phần tử ma trận scores tăng lên $32,000,000$ phần tử (gấp 100 lần), minh chứng cho điểm nghẽn bộ nhớ $O(T^2)$.